

**РУСЕНСКИ УНИВЕРСИТЕТ
“АНГЕЛ КЪНЧЕВ”**

ФАКУЛТЕТ ПРИРОДНИ НАУКИ И
ОБРАЗОВАНИЕ



**UNIVERSITY OF RUSE
“ANGEL KANCHEV”**

FACULTY OF NATURAL SCIENCES AND
EDUCATION

Катедра Информатика и информационни технологии

РЕФЕРАТ

ПО ИЗКУСТВЕН ИНТЕЛЕКТ

на Христо Ценков Христов, Фак. № 236266, 3 Курс, гр. 40А

специалност “Софтуерно инженерство”

**на тема “Клъстеризация. Как ИИ открива скрити групи в
данните”**

Дата:

Проверил:

/гл.ас. д-р В. Козов/

Русе

2026

СЪДЪРЖАНИЕ

Въведение.....	2
Центроидно-базирани.....	3
Алгоритми базирани на разпределение.....	4
Алгоритми базирани на плътност.....	6
Йерархично-базирани.....	7
Графово-базирани.....	8

Въведение

Клъстеризацията намира приложение в машинното обучение без надзор. Тя представлява разделянето на множество от неетикирани данни в групи, чиито елементи по някакъв начин си наподобяват повече от елементите в останалите групи. Развитието на алгоритмите за клъстеризация започва преди близо седем десетилетия и днес са познати много различни видове от тях, като тяхното приложение е сходно. Те се използват в сегментиране на клиенти и потребители в маркетинга и продуктовия анализ, сегментиране на изображения, което намира приложение в компютърното зрение, организация на документи и теми при извличане на информация, откриване на аномалии и пробиви в сигурността и анализ на измами, анализ на биологична таксономия и гени в биоинформатиката. Или по-общо, във всякакви задачи, свързани с анализ и групиране на данни.

Тъй като във всички тези задачи целта е сходна, изборът на правилния алгоритъм обикновено не зависи от областта на приложение, а от разпределението на данните - тяхната геометрия, размери на групите, дали се знае предварително броят на клъстерите (групите), дали групирането е рандомизирано или не, колко голям е обемът данни и колко измерения има.

В зависимост от това се различават пет основни вида алгоритми за клъстеризация базирани на центроиди, на вида разпределение, плътността на данните, йерархия и графи.

В текущия реферат се разглеждат тези пет основни вида алгоритми за клъстеризация, техните предимства, недостатъци и типични представители на всеки един вид.

Центроидно-базирани

Основната идея на центроидно-базираните алгоритми за клъстеризация е всяка група да се представлява от точка (центроид) и всяка данна да бъде част от групата, представлявана от най-близкия до нея центроид. Целта е сумата от евклидовата дистанция, повдигната на втора степен, в групите да бъде:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (1)$$

Класическият алгоритъм, който днес е по-известен като k-близки съсед (K-means) постига това, повтаряйки две основни стъпки - първо присвоява всяка точка до най-близкия до нея центроид, след което преизчислява позицията на центроида като средно аритметично от позициите на точките, попадащи в неговата група. Този алгоритъм е първоначално описан от Лойд през 1957 година и публикуван през 1982 година в контекста на импулсно-кодова модулация, и от Маккуин през 1967 г., който въвежда термина k-близки съсед [1, 2].

Основните предимства на този алгоритъм са неговата простота и скорост, тъй като всяка итерация работи със скорост $O(n * k * d)$, където n са броят точки, d - броят измерения, а k са броят центроиди. Той също така има линеен разход на памет по отношение на броя точки. За набори от данни, при които клъстерите са приблизително изпъкнали, с подобен размер и не са силно повлияни от екстремни стойности, на практика е трудно да бъде надминат. Това е стандартен инструмент за векторна квантизация, квантизация на цветове при компресия на изображения и се използва като бърза предварителна стъпка в други алгоритми (напр. компресия на признаци преди обучение на класификатор).

Въпреки това, той работи добре само при предположение, че наборите данни са конвексни (сферични) и с близки размери. При данни с издължена,

извита или вложена геометрия, алгоритъмът често не ги класифицира правилно. Също така, наличието на шум в данните влияе много на средните стойности и също може да доведе до неправилно класифициране. Друг проблем, който може да настъпи е свързан с това, че броят клъстери k трябва да бъде зададен предварително и алгоритъмът е много чувствителен към началната инициализация, поради което различни случайни инициализации могат да доведат до различни локални минимума за J . Днес това обикновено се избягва като се използва подобрен метод за инициализация, наречен k -means++, при който първият центроид се поставя на случайна позиция, а всеки следващ центроид е максимално отдалечен от останалите [3].

Този алгоритъм е най-добър, когато наборът от данни е относително балансиран, с изпъкнала геометрия, както и в ситуации, когато предварително се знае броят клъстери и скоростта е по-важна от точността.

Алгоритми базирани на разпределение

Когато данните представляват смес от вероятностни разпределения и целим да възстановим параметрите на тези разпределения, най-често те представляват смес от натурални (Гаусови) разпределения (Gaussian Mixture Model, GMM). При тях плътността на данните се моделира като

$$p(x) = \sum_{i=1}^k \pi_i \mathcal{N}(x | \mu_i, \Sigma_i) \quad (2)$$

където теглата π_i се сумират до единица. Всяка компонента има своя средна стойност и ковариационна матрица, така че клъстерите могат да бъдат под формата на елипса и произволно ориентирани, а не само сферични. При този модел параметрите обикновено се оценяват чрез алгоритъма Expectation-Maximization (EM) [4]. EM итеративно редува изчисляване на апостериорната „отговорност“ на всяка компонента за всяка точка (E-стъпка) и обновяване на параметрите чрез претеглено максимално правдоподобие (M-стъпка).

Присвояването на точките към клъстерите става по-гладко, тъй като всяка точка има апостериорна вероятност да принадлежи към всяка компонента. Всъщност k-means е граничен случай на GMM с изотропни ковариации ($\Sigma_i = \sigma^2 I$) и директни присвоявания при $\sigma \rightarrow 0$.

Този метод е подходящ, когато в наборът данни са налични клъстери с елипсовидна геометрия, както и припокриващи се такива, които методите използващи центроиди не могат правилно да класифицират. Предоставя вероятностна оценка, тоест несигурност дали дадена точка принадлежи към клъстер, която е полезна, когато клъстерите реално се припокриват, например при разпознаване на говорители или разделяне на документи по тема. Позволява принципиелен избор на модел чрез критерии, базирани на правдоподобие.

Оценката на пълни ковариационни матрици изисква $O(d^2)$ параметри на всяка компонента, което става нестабилно във високи размерности, варианти с диагонални или споделени ковариации помагат, но намаляват изразителността. Друг недостатък на EM е, че той намира само локален максимум на правдоподобие и е чувствителен към инициализация, поради което k-means често се използва като първа стъпка. Както при k-means, броят на клъстерите k трябва да се знае предварително. Също така, самото Гаусово предположение само по себе си е ограничение, тъй като клъстери, които не са приблизително елиптични (пръстени, полумесеци), не се моделират добре.

Въпреки това, този алгоритъм намира приложение, когато клъстерите са с формата на елипса и се припокриват, както и когато е необходима вероятностна оценка и размера на данните е умерен.

Освен стандартния GMM, съществуват и разширения като вариационни смеси (Variational GMM), които използват вариационен бейсов подход за по-стабилна оценка, както и непараметрични модели като Dirichlet Process GMM, които позволяват автоматично определяне на броя компоненти.

Алгоритми базирани на плътност

Този вид алгоритми са базирани на идеята, че всеки клъстер е максимална свързана област с висока плътност на точките, а точките в области с ниска плътност между клъстерите са шум, а не членове на който и да е клъстер. Определящият алгоритъм за това семейство е DBSCAN, въведен от Естер, Кригел, Зандер и Сю през 1996 г. [5].

DBSCAN има два параметъра: радиус ϵ и минимален брой съседни minPts. Точка е ядро (core point), ако има поне minPts съседни в рамките на разстояние ϵ . Две ядрени точки в рамките на ϵ една от друга принадлежат към един и същ клъстер, а неядрени точки в рамките на ϵ от ядрена точка се прикрепят към нейния клъстер като гранични точки (border points). Всичко останало се маркира като шум. Основният съвременен наследник е HDBSCAN, разработен от Кампело, Мулави и Зандер [6], който премахва глобалния параметър ϵ , като изгражда йерархия от нива на плътност и извлича плоска клъстеризация чрез избиране на най-стабилните клъстери в цялата йерархия. Това го прави устойчив на клъстери с различна плътност, което е основната слабост на класическия DBSCAN.

Едно голямо предимство на този вид алгоритми е, че могат да установяват клъстери с произволна форма, което е невъзможно за методи, базирани на центроид или разпределение. Също така, те откриват броя на клъстерите автоматично от данните и осигуряват начин за определяне и справяне с шум и аномалии. HDBSCAN допълнително обработва клъстери с различна плътност и изисква само един интуитивен параметър, минимален размер на клъстера.

Откъм недостатъци би могло да се отбележи това, че при повече измерения на данните, плътността започва да става трудна за деформиране двойковите разстояния се концентрират, така че контрастът между плътни и редки области изчезва. Също така, единственият глобален ϵ на DBSCAN го прави неподходящ, когато един клъстер е много по-плътен от друг. Производителността зависи от избора на метрика за разстояние, а наивното

изчисляване на най-близките съседи е със сложност $O(n^2)$, макар структури от данни, позволяващи пространствено индексирание (k-d дървета, ball trees) да намаляват тази сложност за малко до умерени на брой измерения.

Поради това, че алгоритмите от този тип позволяват откриване на клъстери с неизвестна форма и брой, както и се справят с аномалии и шум, HDBSCAN се е превърнал в един от стандартните методи в практиката.

Йерархично-базирани

Основната идея при този вид алгоритми е, че вместо да се произведе едно единствено плоско разделение, се създава дърво (дендрограма) от вложени клъстери. Плоска клъстеризация се получава чрез „отрязване“ на дървото на избрана височина. Съществуват две стратегии:

- Агломеративна (отдолу-нагоре): започва се с всяка точка като отделен клъстер, като последователно се сливат най-близките двойки клъстери, докато не остане единствен клъстер.
- Дивизионна (отгоре-надолу): започва се с всичко в един клъстер и рекурсивно се разделя.

Агломеративната стратегия е много по-често срещана на практика. Стъпката на сливане изисква критерий за връзка, който дефинира разстоянието между два клъстера. Той може да бъде единична връзка, тоест минимално двойково разстояние, пълна връзка - максимално, средна връзка и критерият на Уорд, който представлява минимално увеличение на вътрешноклъстерната дисперсия [7]. Изборът на критерий силно влияе върху формата на възстановените клъстери. Единичната връзка може да свързва точки по тънки нишки, докато пълната и критерият на Уорд предпочитат компактни, приблизително сферични клъстери.

Силните страни на тези алгоритми са, че произвеждат структура, която може да бъде интерпретирана на множество мащаби. Самата дендрограма е полезен артефакт, а не просто междинен резултат, тъй като позволява броят клъстери да се избира според дървото, а не да бъде предварително определен.

Също така, резултатите са детерминистични при даден вход и критерий за връзка. Естествено се прилага в области, където подлежащата структура наистина е йерархична (таксономия, филогенетика, организационни данни).

Основният недостатък на тези алгоритми е тяхната производителност, наивните агломеративни алгоритми са със сложност $O(n^3)$ време и $O(n^2)$ памет. Оптимизирани варианти, например за критерия на Уорд и средната връзка, достигат $O(n^2 \log n)$, но това все още е неприемливо при по-големи обеми данни. Също така, след като веднъж бъде извършено сливане, то не може да бъде отменено и ранните грешки се разпространяват. Единичната връзка е особено чувствителна към шум, а пълната връзка е чувствителна към аномалии.

Тези алгоритми се използват при малки до средни набори от данни, където многомащабната структура или самото дърво са полезни. Намира приложение в биоинформатиката за топлинни карти на представяне на гени, както и филогенетични дървета. Също са полезни, когато е нужно да се знае йерархията, а не разпределението да е "черна кутия".

Графово-базирани

При тези алгоритми се построява граф на сходство, при който върховете са наблюдения, а ребрата са претеглени със съвпадението между двойките наблюдения, след което графът се разделя, използвайки неговите спектрални свойства. Най-доминиращият представител на това семейство е спектралната клъстеризация.

При зададена матрица на сходство W , (неутрализираният) граф е $L = D - W$, където D е диагоналната матрица на степените. Първите k собствени вектора на L или на негов вариант с нормализация вграждат точките в k -измерно пространство, в което клъстерите са линейно разделими. Последната стъпка е прилагане на k -means в това вграждане, което дава желаното разделение [8, 9]. Спектралното вграждане трансформира данните така, че групи, свързани в оригиналния граф, се появяват като пространствено

компактни групи в новото пространство, където k-means работи добре. Именно това позволява на този вид алгоритми да се справя със структури като концентрични пръстени, които затрудняват чисто метричните методи.

Тези алгоритми са полезни, тъй като позволяват установяването на клъстери с произволна форма, стига графът на сходство добре да отразява свързаността. Отлични са за сегментация на изображения и за клъстеризация на данни, вече представени като граф като социални мрежи, мрежи от цитати и молекулни структури.

Слабите страни отново са свързани с производителността, тъй като собственото разлагане е бавно $O(n^3)$ за матрици с висока плътност, въпреки че разреждени методи на Ланцош се мащабират добре до по-големи обеми данни, когато графът на сходство е разреден, например при граф на k-най-близки съседи. Производителността също е силно чувствителна към избора на функция за сходство и към построяването на графа. Друг недостатък е и при този вид алгоритми броят клъстери трябва да е предварително известен.

Този вид алгоритми намират приложение, когато данните притежават естествена графова или многообразна структура, клъстерите са с неизвестна форма, но добре свързани и когато е нужно да правим сегментация на изображения и откриване на общности в графи със среден размер.

Заклучение

Въпреки всички гореописани предимства и недостатъци на алгоритмите, изборът на функция за разстояние или сходство често е по-важен от избора на алгоритъм. Въпреки това, ако трябва обобщим, различните видове алгоритми за клъстеризация имат следните предимства и недостатъци:

Таблица 1: Сравнение на алгоритмите за клъстеризация

Тип	Форма на клъстерите	Справяне с шум	Автоматичен брой клъстери	Мащабира се добре	Приложение
Центроидно-базиран	Конвексни, приблизително еднакви по размер	Не	Не	Да	Като основа за други алгоритми, векторно квантуване
Базиран на разпределение	Елипсовидни	Чрез вероятност	BIC/AIC	Умерено	Вероятностно групиране, припокриващи се клъстери
Базиран на плътност	Произволни	Да	Да	Умерено (нискоизмерни данни)	Откриване на аномалии и шум, произволни форми
Йерархично-базиран	Зависи от връзката	Не	Не	Не	Многомащабна структура, таксономии
Графово-базиран	Произволен, ако може да се представи с граф	Не	Евристично	Не	Сегментация на изображения, графови данни

ИЗТОЧНИЦИ

- [1] S. P. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982. (Originally a Bell Labs technical report, 1957.)
 - [2] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, pp. 281–297, 1967.
 - [3] GeeksforGeeks. (2025, July 23). K-means vs K-means++ clustering algorithm.
 - [4] A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum likelihood from incomplete data via the EM algorithm," *Journal of the Royal Statistical Society, Series B*, vol. 39, no. 1, pp. 1–38, 1977.
 - [5] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proc. KDD-96*, pp. 226–231, 1996.
 - [6] R. J. G. B. Campello, D. Moulavi, and J. Sander, "Density-based clustering based on hierarchical density estimates," in *Proc. PAKDD*, pp. 160–172, 2013.
 - [7] J. H. Ward, "Hierarchical grouping to optimize an objective function," *Journal of the American Statistical Association*, vol. 58, no. 301, pp. 236–244, 1963.
 - [8] J. Shi and J. Malik, "Normalized cuts and image segmentation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 22, no. 8, pp. 888–905, 2000.
 - [9] A. Y. Ng, M. I. Jordan, and Y. Weiss, "On spectral clustering: Analysis and an algorithm," in *Advances in Neural Information Processing Systems 14*, pp. 849–856, 2001.
-